
Tarea 01 - Análisis de Datos

Conceptos Básicos

Nombre: Ossian Vladimir Ramirez Hernandez

Grupo: 043

Para que una compañía u organización se tome en serio el uso de datos para mejorar la toma de decisiones, es necesario contar con una variedad de roles encargados de coleccionar, organizar y analizar los datos. Este proceso es extenso, por lo cual se han desarrollado roles especializados que se encargan de distintas partes este. A continuación describimos los tres principales roles, también conocidos como los "pilares" de los roles de datos.

Ingeniería de Datos: El rol del ingeniero de datos se encarga de diseñar y mantener la infraestructura que permite la recolección, el almacenamiento y el procesamiento de los datos. Este debe lidiar con datos incompletos o desordenados, limpiándolos y asegurando su calidad y disponibilidad. Una pieza esencial de este rol es la creación de pipelines de datos, que son flujos automatizados que mueven los datos de un lugar a otro, procesándolos de por medio. Ejemplos de pipelines son el ETL (Extract, Transform, Load) y ELT (Extract, Load, Transform), los cuales definen cuándo y cómo se transforman los datos. En la práctica, su trabajo consiste en crear nuevos pipelines, probar y monitorear pipelines existentes, y mantener y optimizar aquellos que ya están en producción, facilitando el trabajo de analistas y científicos de datos.

Analista de Datos: El rol del analista de datos es aquel que trabaja con los datos después de que han sido recolectados por el ingeniero de datos. Su objetivo es explorar, entender y comunicar hallazgos relevantes para el negocio a partir de dichos datos. Una de sus tareas centrales es el EDA (Exploratory Data Analysis), que consiste en limpiar, transformar y analizar los datos para identificar patrones y tendencias. A partir de este análisis, el analista construye indicadores clave de desempeño (KPIs) y genera visualizaciones, dashboards y reportes utilizando herramientas como PowerBI y Tableau. Nótese que el analista de datos no hace uso de modelos rebuscados, sino de métodos principalmente descriptivos. Su enfoque es más cercano al negocio, y por tanto exige un sólido conocimiento de este, ya que los resultados deben traducirse en métricas e insights claros para los tomadores de decisiones.

Científico de Datos: Por último, el rol del científico de datos es similar al de un analista de datos, con la diferencia de que este busca extraer conocimiento más profundo, yendo más allá del análisis descriptivo. Aunque también realiza EDA, este se centra en aplicar estadística avanzada, machine learning e IA para formular insights. Principalmente se caracteriza por utilizar modelos supervisados y no supervisados de machine learning como el de clasificación, clustering y predicción para explicar comportamientos y anticipar resultados futuros, así como técnicas de optimización para apoyar la toma de decisiones. También requiere un conocimiento del negocio, aunque al ser más especializado su enfoque no es tan cercano como el de un analista. Por último, cabe mencionar que este rol más especializado hace mucho más uso de la programación para desarrollar todos sus modelos.

Estos dos últimos roles hacen mucho uso de lenguajes de programación para elaborar sus análisis exploratorios, el desarrollo de modelos y la generación de visualizaciones. Para esto, es común hacer uso de Python o R. A continuación, se detalla brevemente las diferencias de estos dos lenguajes:

Python y **R** son lenguajes de programación orientados a objetos con enfoques distintos. Python es un lenguaje de propósito general, utilizado no solo para análisis de datos, sino también para desarrollo web, automatización e ingeniería de software. Esto le permite ofrecer una solución al llamado “problema de los dos lenguajes”, ya que el mismo lenguaje puede usarse para prototipos y pruebas, además de usarlo en producción. Además, cuenta con una comunidad muy amplia y una sintaxis más amigable (cercana al inglés vernacular), lo que facilita su aprendizaje. R, en cambio, es un lenguaje especializado en estadística y análisis, diseñado principalmente para estadísticos y académicos. Aunque posee una comunidad sólida, esta es menor que la de Python y su sintaxis suele ser menos intuitiva para principiantes.